

HW2 Task 2 · CIFAR-10 CNN 與前處理 報告

Nathan (a141251) · 2025-10-23

1. 摘要與作業檢核

- 依題目 2-1~2-5 的順序呈現：資料/模型設計、Stride&Kernel 掃描、正確與錯誤樣本、特徵圖、L2 正則化，以及前處理描述+消融。
- Baseline 四層 CNN 在測試集達成 **Top-1 Accuracy=73.79%**（表 1）。我另外附上 **Top-5=97.62%** 作為額外觀察，方便比對官方基準，但也特別註記這項指標非作業硬性要求。
- Stride/Kernel grid（表 2）證實第一層 stride=1 的重要性；L2 sweep（表 3、圖 4）顯示 $\lambda=1e-3$ 可推到 76.31%。
- 定性分析（圖 3、圖 5）解釋模型對不同類別的關注點；第 2-5 節專章列出所有前處理步驟並用表格與圖 6 說明每個 ablation 的影響。
- Reproducibility：python task2_cifar10_pipeline.py --mode baseline --device auto。同學若沒 GPU 可改 --device cpu，其餘模式（stride_filter、l2_study、preprocessing_ablation）可依需求單獨執行。
- 這份題組的困難在於「資料前處理決定成敗」。我刻意把所有 augment/standardize 選項集中管理，才能在報告裡迅速調出結果並做深入比較。

2. Requirement 2-1：資料、模型、Baseline 與 Stride/Kernel 掃描

2.1 Dataset & Pipeline

項目	設定
Dataset	tf.keras.datasets.cifar10（32×32×3、10 類）
Split	Train 45k / Val 5k / Test 10k（固定 seed=20250318）

項目	設定
Standardization	以訓練集均值/標準差做 per-channel z-score (結果存於 <code>channel_stats.json</code>)
Augmentations	RandomCrop(+4 padding)、RandomFlip、ShiftScaleRotate、RandomZoom、RandomTranslation、ColorJitter、Cutout(size=8, prob=0.3)、Mixup ($\alpha=0.2$, 預設關閉)
tf.data	shuffle=10,000、batch=256、平行 map、可選 mixup

2.2 模型與訓練設定

元件	配置
架構	$4 \times [\text{Conv-BN-ReLU-Conv-BN-ReLU-MaxPool}] \rightarrow \text{GlobalAvgPool} \rightarrow \text{Dense}(512) \rightarrow \text{Dropout}(0.5) \rightarrow \text{Dense}(10, \text{softmax})$
Filters/Kernels	[64, 128, 256, 512] , kernel 預設 [3,3,3,3] , grid 允許 [5,3,3,3] , [5,5,3,3]
Optimizer	AdamW (lr=2e-4, weight_decay=1e-4)
Scheduler	5-epoch 線性 warmup + CosineDecayRestarts(first_decay_steps=20, T_mul=2, M_mul=0.9)
Regularization	Dropout(0.5) + optional L2 ; EarlyStopping 監控 val top-1 (patience=12)
Mixed Precision	可透過 <code>--mixed-precision</code> 啟用，但本報告使用 FP32

2.3 Baseline 成效與學習曲線

Split	Loss	Top-1	Top-5*
Train	1.162	71.78%	97.68%
Val	1.128	73.72%	97.72%
Test	1.130	73.79%	97.62%




圖 1 Train/Val learning curve；右上角標註測試集 Top-1=73.79%，Top-5=97.62%（星號 * 表示額外指標，非作業要求）。




圖 2 混淆矩陣顯示 bird/cat 等相似物種最容易混淆；交通工具類別最穩定。

我注意到 train/val loss 幾乎重疊，但 Top-1 無法超過 74%，代表這個網路已經接近容量上限。尤其是 3（cat）與 5（dog）的錯誤率居高不下，顯示 32×32 解析度對毛髮細節仍然不夠。這也說明為什麼後面要做前處理消融：與其盲目堆疊層數，不如先把資料餵得更乾淨。

2.4 Stride / Kernel Grid (Requirement 2-1)

Tag	Strides	Kernels	Test Top-1	Test Top-5
stride1-1-1-1_kernel3-3-3-3	[1,1,1,1]	[3,3,3,3]	73.86%	97.90%
stride1-1-1-1_kernel5-3-3-3	[1,1,1,1]	[5,3,3,3]	72.79%	97.78%
stride1-1-1-1_kernel5-5-3-3	[1,1,1,1]	[5,5,3,3]	73.08%	97.75%
stride1-1-2-1_kernel3-3-3-3	[1,1,2,1]	[3,3,3,3]	64.90%	96.85%
stride1-1-2-1_kernel5-5-3-3	[1,1,2,1]	[5,5,3,3]	67.18%	96.89%
stride2-1-1-1_kernel3-3-3-3	[2,1,1,1]	[3,3,3,3]	61.36%	95.78%

解讀：只要第一層 stride 提到 2，Top-1 立刻掉 8~12%，驗證 Requirement 2-1「分析 stride/filter 影響」的觀察。Kernel 改成 5×5 影響極小 (≤1%)，所以我傾向保留 3×3 以降低計算量。

我另外把 FLOPs 粗估了一下：把第一層 stride 設為 2 確實可以省下近 30% 的運算，但代價是模型會把羽毛與鬍鬚這類細節全部壓扁，所以在 CIFAR-10 這種細粒度任務上毫無優勢。反而 kernel=5 的組合讓我看見「盲目擴大 receptive field」並不能補救解析度的流失，之後若要升級模型，我會優先從更深的架構（例如 ResNet）來提升表現。

3. Requirement 2-4：L2 正則化

λ	Test Top-1	Test Top-5	Weight Norm
0	73.78%	97.87%	741.88
1e-5	73.63%	97.87%	736.79
5e-5	73.98%	97.65%	696.92
1e-4	73.91%	97.93%	654.94
5e-4	75.67%	98.08%	469.08
1e-3	76.31%	98.01%	356.42




圖 4 $\lambda=5e-4$ 之後，權重分佈明顯集中於 0 附近，對應表 3 的 *norm* 降幅。

心得： $\lambda=1e-3$ 雖然讓 Top-5 略降 0.1%，但 Top-1 提升到 76.31%，且 weight norm 大幅下降（356）。我在報告正文強調這是 Regularization 的甜蜜點，符合題目希望我們「討論其 effect」的精神。

值得一提的是，當我把 L2 與 AdamW 的 weight decay 同時設太大時，模型會在前 10 個 epoch 就失去學習動力，所以我最後維持 `weight_decay=1e-4`，只動 L2。這個經驗提醒我：在 CIFAR-10 上，正則化其實來自多個管道（增強、weight decay、dropout），要做 sweep 就得先固定其他因素，否則結果會互相抵銷。

4. Requirements 2-2 & 2-3：正確/錯誤樣本與特徵圖





圖 3 正確案例多為背景單純的 Airplane/Ship；錯誤案例多為姿勢怪異的 Cat/Dog。

我觀察到：

- 飛機、船等交通工具在背景顏色與輪廓都很乾淨時最容易判對。
- 貓狗若被切到或背景雜亂，模型會誤判成 Deer/Horse，顯示需要更多幾何增強。

Class 0 - Block 1



Class 0 - Block 3




圖 5 同一架飛機在 Block 1/Block 3 的特徵圖：前者抓顏色邊緣，後者只留下機身輪廓。

在 `HW2/reports/task2/feature_map_observations.md` 中我針對 0~9 十個類別逐一描述：Block 1 聚焦顏色與大尺度邊緣、Block 2 開始強調材質與對比、Block 3 則萃取整體輪廓。這些段落補上了 Requirement 2-3 的「describe how feature maps change with increasing depth」。

我特別喜歡比較 cat vs dog 的特徵圖：Block 1 看到的是耳朵與背景顏色，Block 2 會開始強調毛皮紋理，Block 3 則只留下頭部輪廓。當模型把狗誤判成貓時，通常是因為 Block 3 只看到圓圓的頭而忽略了口鼻突出，這樣的視覺化讓我確信「數據增強應該聚焦在姿勢」而不是盲目增加顏色抖動。

5. Requirement 2-5：Preprocessing 說明與消融

5.1 步驟整理（題目 2-5 所需的敘述）

1. 標準化：統一用 training split 的 channel mean/std；推論時直接套用同一組統計。

2. 幾何增強：Pad+RandomCrop, Flip, ShiftScaleRotate, RandomZoom/Translation 共同模擬視角與比例差異。
3. 色彩增強：ColorJitter 擾動亮度/對比/飽和度/Hue。
4. 遮罩：Cutout(size=8, prob=0.3) 偶爾遮住局部；若需要更平滑的結果可關閉。
5. Mixup：保留參數 $\alpha=0.2$ ，但 baseline 預設關閉，僅在 ablation 中測試。

5.2 Ablation 結果

Variant	Test Top-1	Test Top-5	Macro F1	說明
baseline	73.96%	97.71%	0.7336	完整流程（Mixup off）
no_standardization	74.21%	98.07%	0.7373	移除 z-score，曲線更平滑
no_augmentation	72.47%	96.55%	0.7234	全部增強關閉 → Top-1 掉 1.5%
no_cutout	74.97%	97.80%	0.7441	刪除 Cutout 反而提升，顯示 CIFAR-10 不一定需要遮罩
no_color	73.85%	97.85%	0.7326	去除色彩抖動，影響有限
no_mixup	73.96%	97.82%	0.7338	Baseline 就沒開，結果相同




圖 6 移除 Cutout 後驗證曲線更平滑，印證表格中的提升。

結論：我在本節開頭完整列出所有前處理步驟，再用表格與圖示分析其效應，確保報告中的第「2-5」節真正說明 preprocessing（而不是只貼數字），符合題目要求。

額外心得：Cutout 在這個 baseline 反而有害，因為 32×32 的圖一旦被挖洞，很容易把主體整個遮掉；改成較柔和的 Mixup 反而更友善。此外，「no_standardization」雖然微幅提升 Top-5，但我觀察到 loss

波動變大，代表 z-score 仍有穩定訓練的價值。這些結果讓我之後在處理彩色資料集時會先從「幾何增強 + 輕量正則化」開始，再視任務調整 Cutout/Mixup 的強度。

6. 訓練效率與重現

任務	Epochs	時間 (min)
baseline	37	38.66
stride1-1-1-1_kernel3-3-3-3	36	37.66
stride1-1-2-1_kernel5-3-3-3	36	39.78
l2_1e-03	37	40.73
preprocess_no_cutout	37	36.27
preprocess_no_augmentation	37	6.44 (無增強 → pipeline 最快)

- **指令：**python task2_cifar10_pipeline.py --mode baseline --device auto ；其他模式可單獨執行避免 --mode all 的 8+ 小時成本。
- **資料輸出：**所有圖表與 CSV 都整理在 HW2/reports/task2 ，助教可對照表格/圖 1～6 。

由於完整 --mode all 需要 8 小時以上，我實際操作時會根據報告需求拆開執行：先跑 baseline、再跑 stride 與 L2、最後才挑幾個前處理變體。每次實驗結束都會在 reports/task2/images/ 產出對應的圖檔，這讓我在撰寫 2-5 節時可以直接引用，不用重新截圖。

7. 結論

- Requirement 2-1：表 1、圖 1～2 與表 2 詳細記錄 Dataset、模型設定、learning/test accuracy、stride/filter 分析。
- Requirement 2-2：圖 3 的正確/錯誤樣本附上口語化解讀。
- Requirement 2-3：圖 5 與 feature_map_observations.md 描述不同 block 的特徵轉變。
- Requirement 2-4：表 3 與圖 4 呈現 L2 對權重與效能的影響。
- Requirement 2-5：第 5 節用文字+表格+圖 6 說明所有前處理與 ablation。
- 另外附上的 Top-5 指標僅作為補充註記，主體仍聚焦在題目要求的 Top-1 與分析。